

Analiza i predikcija kriminalnih aktivnosti u Los Angelesu

Miljana Marjanović E2 99/2024

Milena Marković E2 100/2024

1. Definicija problema

Potrebno je prikupiti i analizirati podatke o kriminalnim aktivnostima u Los Angelesu, zajedno sa podacima o vremenskim prilikama i demografskim podacima različitih delova grada. Poseban fokus biće na istraživanju potencijalnih korelacija između kriminalnih aktivnosti i prethodno navedenih dodatnih faktora. Nakon obrade i analize podataka, biće izvršeno testiranje različitih modela i algoritama kako bi se predvidele kriminalne aktivnosti na području Los Angelesa.

2. Motivacija problema rešavanog u projektu

Analizom kriminalnih aktivnosti bi se mogli uočiti određeni šabloni, što bi policijskim službenicima omogućilo jasan pregled situacije na terenu. Ovakav pristup daje informacije o zonama povećanog rizika i može pomoći pri pravljenu rasporeda policijskih patrula. Uzimajući u obzir demografske podatke i podatke o vremenskim prilikama, ovakva analiza može pružiti bržu i efikasniju reakciju nadležnih organa, čime bi se direktno uticalo na smanjenje stope kriminala.

3. Relevantna literatura

3.1 Exploratory data analysis of crime report, 2021 [\[pdf\]](#)

Tema rada: Rad se bavi analizom i vizualizacijom podataka o kriminalnim aktivnostima koristeći R programski jezik. Grafici prikazani u ovom radu ilustruju distribuciju zločina po godinama, mesecima, danima, polu...

Podaci: Rad koristi podatke o kriminalnim aktivnostima u Los Angelesu u periodu od 2010. do 2017. godine. [\[link\]](#) Skup podataka se sastoji od 2 000 000 zapisa sa sledećim atributima: datum, vreme i tačna lokacija izvršenja krivičnog dela, datum prijave, tip krivičnog dela, da li je korišćeno oružje, godine i pol žrtve...

Metodologija: Ovo je rad koji se bavi analizom podataka, tako da metodologija nije u prvom planu. Korišćene su klasične tehnike identifikacije varijabli, pretprocesiranja podataka, a za analizu su korišćene univarijantna, bivarijantna i multivarijantna analiza. Za vizualizaciju podataka koristi se ggplot2 paket.

Zaključak: Uzećemo skup podataka iz ovog rada i proširićemo ga dodatnim podacima o vremenskim prilikama i demografskim karakteristikama. Nakon toga biće primenjene iste tehnike za analizu kao i u navedenom radu, kako bismo otkrili nove obrasce i dublje razumeli faktore koji utiču na kriminal.

3.2 Predikcija rizika i klasifikacija ozbiljnosti sudara motornih vozila u Njujorku, 2021 [\[pdf\]](#)

Tema rada: Rad se bavi analizom faktora koji direktno utiču na povećanje verovatnoće sudara motornih vozila (podaci o sudaru, vremenske prilike, protok saobraćaja). Takođe, u radu se stavlja fokus na predviđanje sudara i klasifikaciju težine sudara.

Podaci: Korišćena su tri javno dostupna skupa podataka (NYC Open Data) [\[link\]](#) koji sadrže podatke sudarima i informacije o protoku saobraćaja na pojedinačnim segmentima ulica. Informacije o vremenu su preuzete pomoću API-ja koji pruža IBM Weather [\[link\]](#).

Pretprocesiranje podataka: Kako je lokacija predstavljala ključno obeležje za spajanje sva tri skupa podataka, odbačeni su svi podaci kojima je ovaj atribut nedostajao. Spajanje informacija o sudarima sa informacijama o vremenskim prilikama izvršeno je i na osnovu datuma i sata u kom se desio sudar. Kako su ovde prisutni ciklični podaci o datumu i vremenu (npr 23h i 00h), primenjene su sinusna i kosinusna transformacija. Za kategorička obeležja je korišćen one-hot encoding. Da bi se model za predikciju mogao obučiti, za svaki uzorak iz skupa podataka je generisan po jedan negativni primer koji je imao isti datum, dok su ulica i vreme birani nasumično, pod uslovom da se u to vreme istog dana na datom mestu nije desio sudar. Pre obučavanja, skup je podeljen na trening (90%) i testni skup (10%).

Metodologije: Problem predikcije se ovde posmatra kao problem binarne klasifikacije (da li se sudar desio ili se nije desio), zbog toga su korišćeni modeli zasnovani na stablu (Random Forest, Extra Trees, LightGBM, XGBoost i CatBoost), a pored njih je isproban i KNN model.

Evaluacija rešenja: Za evaluaciju modela predikcije korišćene su metrike: precision, accuracy, recall i F1 score. Navedeno je da se CatBoost pokazao kao najbolji model za predikciju sudara sa F1-skorom od 0,7.

Zaključak: Iz ovog rada uzećemo način pretprocesiranja podataka, te ćemo koristiti identičan pristup čišćenja i spajanja skupova podataka o kriminalnim aktivnostima, vremenu i demografskim karakteristikama. Takođe, korišćemo navedene modele za predikciju i upoređićemo koji od njih daje najbolje rezultate na našem skupu podataka. Za evaluaciju ćemo koristiti iste metrike kao i navedeni rad.

3.3 A Crime Data Analysis of Prediction Based on Classification Approaches, 2022 [\[pdf\]](#)

Tema rada: Rad se fokusira na predikciju tipa kriminalnih aktivnosti u Bostonu. Glavni cilj je uporediti performanse tri algoritma nadgledanog učenja: Decision Tree, Naïve Bayes i Logistic Regression.

Podaci: Za analizu su korišćeni podaci iz baze izveštaja o kriminalnim incidentima u Bostonu, koji obuhvataju period od sredine 2015. godine do prve polovine 2018. godine. [\[link\]](#) Skup podataka klasifikuje tip incidenta i sadrži detalje o vremenu i lokaciji svakog događaja.

Pretprocesiranje podataka: Nedostajuće vrednosti su popunjene korišćenjem srednje vrednosti odgovarajućeg atributa, nakon čega su podaci normalizovani na opseg od 0 do 1. Nakon toga, podaci su podeljeni u trening (80%) i testni skup (20%) radi obuke i evaluacije modela.

Metodologije: Cilj rada bio je predvideti tip kriminalne aktivnosti. U tu svrhu korišćeni su sledeći algoritmi: Decision Tree, Naïve Bayes i Logistic Regression. Među njima, Decision Tree je pokazao najbolje rezultate.

Evaluacija rešenja: Metrike korišćene za evaluaciju su: precision, recall i F1 score. Decision Tree je dao najbolje rezultate sa skorom 1.00 kod sve tri korišćene metrike.

Zaključak: Naša ideja je da upotrebimo ove algoritme, uporedimo ih sa algoritmima iz prethodnog rada (Random Forest, Extra Trees, LightGBM, XGBoost i CatBoost) i analiziramo njihove performanse kako bismo utvrdili koji model pruža najpreciznije i najpouzdanije rezultate za naš skup podataka.

4. Skup podataka

Podaci o kriminalnim aktivnostima [\[link\]](#)

Kao početni skup koristićemo podatke o kriminalnim aktivnostima u Los Anđelesu od 2010. do 2019. godine. Ovaj skup sadrži preko 2 000 000 zapisa i uključuje attribute poput tačnog vremena i lokacije incidenta, kao i tipa krivičnog dela. Pored ovih osnovnih informacija, skup poseduje i dodatne attribute, poput godina, pola i rase žrtve, prisustva oružja, kao i specifičnosti lokacije incidenta (npr. da li se dogodio u restoranu, na parkingu ili na ulici). Svi ovi atributi biće predmet detaljne analize, kako bismo identifikovali ključne faktore koji će biti osnova za dalju obradu i istraživanje.

Podaci o socio-ekonomskom statusu [\[link\]](#)

Los Anđeles se sastoji 15 delova (engl. districts), za svaki od distrikta postoje podaci dobijeni popisom stanovništva iz 2010. godine. Ovi podaci obuhvataju raznovrsne distribucije stanovništva, uključujući informacije o rasi, starosnoj dobi, polu i drugim ključnim demografskim faktorima. Koristićemo podatke ovog popisa pod pretpostavkom da se situacija nije značajno promenila u periodu od 2010. do 2019. godine. Na istom sajtu još uvek nisu objavljeni podaci za popis iz 2020. godine, ukoliko pronađemo traženi skup podataka, koristićemo aproksimaciju demografskih podataka navedena dva popisa.

Podaci o vremenskim prilikama [\[link\]](#) ili [\[link2\]](#)

Podatke o vremenskim prilikama preuzećemo sa jednog od dva ponuđena izvora. Atributi koje ćemo razmatrati uključuju temperaturu, padavine, vlažnost vazduha, brzinu vetra i druge relevantne faktore. Na osnovu analize odlučićemo koji od atributa imaju najznačajniji uticaj i oni će biti uključen u naš dalji rad.

5. Metodologija

Nakon preprocesiranja svih podataka, spojićemo relevantne informacije o kriminalnim aktivnostima, vremenskim prilikama i demografskim karakteristikama u jedan skup podataka. Ovaj skup ćemo koristiti za dalju analizu, posle koje ćemo za svaki podatak generisati odgovarajući negativan primer. Negativan primer će zadržati isti datum, dok će lokacija biti nasumično odabrana, uz uslov da na tom mestu u to vreme nije bilo kriminalnog incidenta. Podatke ćemo labelirati kao pozitivne i negativne. Zatim ćemo testirati većinu navedenih metoda za predikciju kriminalnih aktivnosti, kao što su Random Forest, Extra Trees, LightGBM, XGBoost, CatBoost, Decision Tree, Naïve Bayes i Logistic Regression. Na osnovu performansi svakog modela, utvrdićemo koji algoritam daje najbolje rezultate.

6. Metod evaluacije

Za evaluaciju predikcije korišće se metrike: precision, accuracy, recall i F1 score. Podaci će biti podeljeni na trening, validacioni i testni skup u odnosu 80/10/10.